

97 篇逐篇算法图谱（链接版）

原图谱 PDF（64.3 MB）内嵌 97 张**论文原文截图**。逐篇版权核查（arXiv OAI-PMH）结果：**可再分发 41 篇 / 不可 50 篇 / 待查 6 篇**——46 篇是 arXiv 非独占许可，只授权 arXiv 分发，未给公众复使用权；4 篇 CC BY-NC-ND 连缩放裁剪都不允许。因此公开仓库**不分发截图**，改为本索引。

源 PDF 已用 SHA-256 与 arXiv 下载件比对确认（抽检 9 篇全部一致），故 arXiv 声明的许可适用于截图。

编号	论文	年	arXiv	arXiv 声明许可	机制要点（中文原稿）
A001	Manipulation Facing Threats: Evaluating Physical Vulnerabilities in End-to-End Vision Language Action Models	2024	2409.13174	arXiv non-exclusive licence	（1）对干净场景构造模糊、高斯噪声、亮度变化、视觉文字和贴片条件；（2）在同一指令下逐回合运行 VLA；（3）白盒时直接对目标输出反传，黑盒时在 MLLM 的图文对上求可转移贴片；（4）用固定掩码把贴片粘贴到每帧；（5）按任务级成功/失败而非单帧分类统计后果。
A002	Run-time Observation Interventions Make Vision-Language-Action Models More Visually Robust	2024	2410.01971	CC BY	（1）GPT-4o 从首帧和指令提出无关物体/背景；（2）Grounded-SAM2 将文本区域逐帧分割；（3）逐区域施加模糊或噪声并重复采样动作块；（4）计算原动作与扰动动作的加权差；（5）只对 $\Delta_f \geq \tau$ 的“模型敏感但任务无关”区域做修补或背景替换；（6）不微调权重，直接用编辑图像闭环控制。
A003	Exploring the Adversarial Vulnerabilities of Vision-Language-Action Models in Robotics	2024	2411.13587	arXiv non-exclusive licence	（1）把每个动作维度的 256 个 bin 去标记为物理值；（2）UADA 选择距干净动作最远的软目标；（3）UPA 重点最大化三维位置偏差；（4）TMA 用指定七维目标做交叉熵；（5）每次迭代随机平移、错切、旋转贴片并做内循环梯度更新；（6）把同一贴片用于后续闭环帧。
A004	SafeVLA: Towards Safety Alignment of Vision-Language-Action Model via Constrained Learning	2025	2503.03480	CC BY-NC-SA	（1）把角落、盲区、易碎物群、临界物和危险设备编码为组合安全谓词；（2）在 ProcTHOR/Objaverse 场景中诱发长尾风险；（3）把谓词违规转成时间步成本；（4）以拉格朗日乘子交替更新策略与约束强度；（5）在常规、长尾、极端失败和分布外条件下分别验收。
A005	BadVLA: Towards Backdoor Attacks on Vision-Language-Action Models via Objective-Decoupled Optimization	2025	2505.16640	CC BY	（1）冻结参考模型产生干净特征锚点；（2）阶段一只训练感知模块，使干净特征贴近参考，同时把触发特征推离干净子空间；（3）冻结已植入触发的感知模块；（4）阶段二仅用干净数据训练骨干和动作头；（5）部署时触发特征落到动作头未见区域，引发随机或语义不一致动作。
A006	Adversarial Attacks on Robotic Vision Language Action Models	2025	2506.03350	CC BY	（1）把每个自由度的连续动作映射到 256 个稀有词 token；（2）定义目标动作序列的负对数似然；（3）逐坐标计算候选 token 梯度并贪心替换后缀；（4）单步攻击只用首帧嵌入；（5）持续攻击把多帧/增广图像的损失相加；（6）用同一后缀测试跨检查点转移。
A007	SAFE: Multitask Failure Detection for Vision-Language-Action Models	2025	2506.09937	arXiv non-exclusive licence	（1）从动作解码前的最后层抽取并聚合隐藏状态；（2）SAFE-MLP 独立评分后累积，SAFE-LSTM 直接处理时序；（3）用成功/失败轨迹训练轻量探针；（4）只用成功校准轨迹估计单侧、随时间变化的 functional conformal band；（5）当 $s_t > \delta_t$ 时触发失败告警。

编号	论文	年	arXiv	arXiv 声明许可	机制要点（中文原稿）
A008	ANNIE: Be Careful of Your Robots	2025	2509.03383	CC BY	(1) VLA 在干净帧上给参考动作 (a_t)；(2) 双视角 ResNet 与风险嵌入融合，预测方向/尺度 Δa_t； (3) 令 $\tilde{a}_t = a_t + \Delta a_t$；(4) 以该动作做目标对图像执行 PGD；(5) 密集版攻击每帧，稀疏版每 S 帧，自适应版按预测尺度动态选择帧。
A009	FreezeVLA: Action-Freezing Attacks against Vision-Language-Action Models	2025	2509.19870	arXiv non-exclusive licence	(1) LLM 生成描述同一场景的多条提示；(2) 内层找对冻结最“难”的提示：定位梯度最大词并用同义词替换，若冻结概率更低则接受；(3) 得到困难提示集 (P^*)；(4) 外层汇总所有困难提示的图像梯度；(5) 按符号梯度更新并投影到 L_∞ 球；(6) 交替重复直至跨提示冻结稳定。
A010	FailSafe: Reasoning and Recovery from Failures in Vision-Language-Action Models	2025	2510.01642	CC BY	(1) 自动生成平移、旋转与 no-op 故障轨迹；(2) 从正确轨迹的受限窗口为每个 (P_d) 采样 (P_c)； (3) 计算七维 ΔA；(4) 重放 $A \rightarrow P_d \rightarrow P_c \rightarrow B \rightarrow C \rightarrow D$，仅保留真正恢复成功的样本；(5) 构造约 131k 故障-动作与 56k 正常样本微调 LLaVA-OneVision；(6) 部
A011	Goal-oriented Backdoor Attack against Vision-Language-Action Models via Physical Objects	2025	2510.09269	CC BY-NC-SA	(1) 用 SpaceMouse 收集原任务演示；(2) 保持语言指令不变，在场景中放入物理触发物；(3) 由人示范把触发物拿到攻击者指定区域的 ($A_{\{adv\}}$)；(4) 按 ($IR=M/(N+M)$) 混入干净数据；(5) 用常规行为克隆训练 OpenVLA/π_0；(6) 触发时按三级标准判断是否真正完成恶意目标。
A012	DropVLA: An Action-Level Backdoor Attack on Vision-Language-Action Models	2025	2510.10932	CC BY-NC-ND	(1) 随机抽取少量 episode；(2) 找“夹爪已闭合”等关键决策的触发起点集合 (U_e)；(3) 从起点向后同时追加文本触发并变换视觉帧；(4) 把长度 (L) 的连续夹爪标签由闭合翻成释放；(5) 保持所有重叠动作窗口标签一致；(6) 用标准微调损失训练并在触发对齐时间统计响应延迟和 ASR。
A013	Phantom Menace: Exploring and Enhancing the Robustness of VLA Models Against Physical Sensor Attacks	2025	2511.10008	CC BY-NC-ND	(1) 在数字域建模八种传感器通道；(2) 用投影、激光、EMI 与超声设备记录真实攻击模式；(3) 把真实模式参数化后叠加到 LIBERO 观测；(4) 以弱/中/强三级在 OpenVLA、OpenVLA-OFT、π_0、π_0-fast 上闭环运行；(5) 混合攻击样本微调；(6) 回到 Franka 真机验证迁移。
A014	AttackVLA: Benchmarking Adversarial and Backdoor Attacks on Vision-Language-Action Models	2025	2511.12149	arXiv non-exclusive licence	(1) 统一复现 PGD、UADA、UPA、TMA、RoboGCG、FreezeVLA、BadVLA 与 TabVLA； (2) BackdoorVLA 抽取少量演示；(3) 同时插入视觉物体与 <i>~magic~</i> 文本；(4) 把整段动作替换为目标序列；(5) 用干净/投毒联合似然训练；(6) 在 OpenVLA、SpatialVLA、π_0-fa

编号	论文	年	arXiv	arXiv 声明许可	机制要点（中文原稿）
A015	When Alignment Fails: Multimodal Adversarial Attacks on Vision-Language-Action Models	2025	2511.16203	arXiv non-exclusive licence	(1) SGCG 找梯度范数最大的词位；(2) 从通用候选与指代、属性、空间、逻辑等类别候选中做词性一致替换；(3) 视觉白盒分支优化环境物体或机械臂贴片以最大化动作 (L_2) 偏差；(4) 黑盒分支加入多种噪声；(5) 跨模态分支联合优化视觉与文字，使表示对齐和动作同时偏离。
A016	When Robots Obey the Patch: Universal Transferable Patch Attacks on Vision-Language-Action Models	2025	2511.21192	arXiv non-exclusive licence	(1) 计算干净/贴片视觉特征；(2) 内层 PGD 学习不可见的样本级 σ ，使特征邻域变“更难”；(3) 冻结 σ ，外层最大化 (L_1) 特征偏移与排斥式 InfoNCE；(4) PAD 使文字到视觉的注意力增量集中到贴片；(5) PSM 让贴片语义远离任务文本、靠近诱导探针；(6) 用随机位置/视角训练同一 δ 后直接转移。
A017	ADVLA: Attention-Guided Patch-Wise Sparse Adversarial Attacks on Vision-Language-Action Models	2025	2511.21663	arXiv non-exclusive licence	(1) 固定干净投影特征 (F_{clean})；(2) 在当前图像上初始化小噪声；(3) 最大化对抗特征与干净特征的余弦差；(4) AW 用注意力加权像素梯度；(5) TKM 只保留 top-k 注意 patch 的梯度；(6) TKL 只在 top-k patch 特征上算损失；(7) 按 PGD 更新并投影像素范围。
A018	VLSA: Vision-Language-Action Models with Plug-and-Play Safety Constraint Layer	2025	2512.11891	arXiv non-exclusive licence	(1) VLM 从任务和图像抽取障碍名称；(2) GroundingDINO 定位 2D 框；(3) 融合深度并反投影到世界坐标；(4) 过滤点云并拟合障碍 MVEE，同时用椭圆近似末端；(5) 由两椭圆的分离距离构造 CBF；(6) 求离名义动作最近且满足 $(\ h\ _{\text{ge}} - \alpha(h))$ 的控制；(7) 无风险时透传原动作。
A019	Stable Language Guidance for Vision-Language-Action Models	2026	2601.04052	arXiv non-exclusive licence	(1) 把原指令视为潜在意图 (z) 的一个有噪样本；(2) LLM 生成空间描述、子任务拆分和重写组成的稠密邻域；(3) 对所有重写平均动作负对数似然，学习句法不变表示；(4) 分别算 $s(a \cdot o, l)$ 与视觉 affordance prior $s(a \cdot o, \emptyset)$ ；(5) 取差得到纯语义残差；(6) 以系数放大残差后解码动
A020	State Backdoor: Towards Stealthy Real-world Poisoning Attack on Vision-Language-Action Model in State Space	2026	2601.04266	arXiv non-exclusive licence	(1) 均匀初始化一组状态扰动；(2) 用代理分别计算触发失败损失 (f_1)、正常功能损失 (f_2) 与状态距离 (f_3)；(3) 以偏好引导遗传算法选择；(4) 交叉、变异并以软约束淘汰太显眼或无效个体；(5) 取得最小综合目标的 (t^*)；(6) 收集该初态下的恶意演示微调；(7) 部署时仅设置初态即可触发。

编号	论文	年	arXiv	arXiv 声明许可	机制要点（中文原稿）
A021	SilentDrift: Exploiting Action Chunking for Stealthy Backdoor Attacks on Vision-Language-Action Models	2026	2601.14323	arXiv non-exclusive licence	（1）从语言解析目标物并视觉定位；（2）找末端进入目标距离阈值的关键时刻 (t_{start})；（3）仅在短窗口加入触发；（4）用 Smootherstep 从 0 平滑增至最大偏移；（5）把偏移叠加到每个增量动作；（6）动作块开环积分使毫米级偏移积成厘米级 near-miss；（7）用混合轨迹正常微调。
A022	Inject Once Survive Later: Backdooring Vision-Language-Action Models to Persist Through Downstream Fine-tuning	2026	2602.00500	arXiv non-exclusive licence	（1）在多种代表性下游适配上比较每个模块；（2）计算参数平均绝对差、Fisher 加权差和 CKA 激活漂移；（3）归一化融合为稳定度 (S_i)，在漂移预算内选最稳定模块；（4）冻结其余参数；（5）只在稳定模块用干净与投毒损失建立触发-动作映射；（6）模拟用户仅用干净数据微调；（7）测后门存活和干净效用。
A023	SAFE-Dict: Concept-Based Dictionary Learning for Inference-Time Safety in Vision Language Action Models	2026	2602.01834	arXiv non-exclusive licence	（1）Qwen2.5-VL 从数据挖掘对象/实体；（2）Qwen-3 为每个概念生成同风格刺激并评危险权重；（3）抽取最后层激活，对每概念做 PCA 取主方向；（4）拼成字典 D；（5）推理时用 ElasticNet 稀疏分解 h；（6）若全局危险分数超阈值，仅衰减 top-k 危险概念；（7）把字典外残差原样加回。
A024	TRAP: Hijacking VLA CoT-Reasoning via Adversarial Patches	2026	2603.23117	arXiv non-exclusive licence	（1）先以指令遮蔽和跨样本 CoT 打乱确认 CoT 对动作的影响；（2）在多任务离线轨迹逐帧粘贴同一 δ ；（3）交叉熵对齐目标 CoT token；（4）离散动作以 CE、连续动作以轨迹 MSE 对齐；（5）加入内容特征和 TV 使贴片看似花纹；（6）用 PGD 或 Deep Image Prior 优化；（7）训练时加入单应、颜色、噪
A025	VLA-Forget: Vision-Language-Action Unlearning for Embodied Foundation Models	2026	2604.03956	arXiv non-exclusive licence	（1）按遗忘梯度与保留梯度比值选视觉、投影和上层语言-动作参数；（2）阶段一削弱目标视觉证据；（3）阶段二切断特定图像-词语对齐；（4）阶段三清除残留动作先验；（5）同时优化 retain、forget、mismatch 与感知蒸馏；（6）用 PCGrad 投影冲突梯度；（7）若遗忘不足再扩展可编辑层，否则停止并做任务/安全审计。
A026	JailWAM: Jailbreaking World Action Models in Robot Control	2026	2604.05498	arXiv non-exclusive licence	（1）用专门危险动作模板提示 LLM 生成候选；（2）WAM 开环生成动作；（3）VTM 累积相对动作成三维路径并投影到 xy/xz 图；（4）Qwen3-VL-2B 风险判别器快速筛掉安全候选；（5）仅将 Level 1/2 候选送入 RoboTwin 闭环；（6）人工复核振荡、越界、碰撞等后果并给最终标签。
A027	FlowHijack: A Dynamics-Aware Backdoor Attack on Flow-Matching	2026	2604.09651	CC BY	（1）选倒置杯子、打开抽屉等对象状态或背景物作为上下文触发；（2）只在小流时间 $\tau \in [0, \tau_0]$ 注入恶意去噪方向；（3）ODE 在后续路径放大早期方向误差；（4）Pose-Locking 指向固定姿态，Initial-

编号	论文	年	arXiv	arXiv 声明许可	机制要点（中文原稿）
	Vision-Language-Action Models				Perturbation 给正常动作加持续小偏移；(5) 用 Dynamics Mimicry 匹配
A028	HazardArena: Evaluating Semantic Safety in Vision-Language-Action Models	2026	2604.12447	arXiv non-exclusive licence	(1) 从 ISO 13482 与 AutoRT 提取食品、财产、化学、隐私、火、电、人身风险；(2) 构造可交互资产；(3) 按 Pick-Place/Insert/Pour/Explore 模板组合风险源与受害目标；(4) 只替换 actor-target 语义生成 safe/unsafe twins；(5) 仅用 safe 演示微调；(6) 按
A029	TRAP: Tail-aware Ranking Attack for World-Model Planning	2026	2605.01950	CC BY	(1) 在干净观测生成候选轨迹及分数；(2) 为每条轨迹选干净高分 top-quantile 作为 tail mask；(3) 贴片条件下重算分数差 ΔJ ；(4) 只压低决策关键 tail，并用 softmin 聚焦最难压低的候选；(5) sign gate 惩罚分数反向升高；(6) magnitude gate 阻止超过边际的过度压
A030	Capability and Robustness Cannot Both Be Free: An Information-Theoretic Bound for Vision-Language-Action Models	2026	2605.25889	CC BY	先用互信息定义能力 $\text{Cap}(\pi) = I(A^*; A_\pi)$ ；再把稳健性定义成干净/攻击动作的一致信息，减去策略动作对攻击扰动的直接泄漏；随后对 $A^* \rightarrow X \rightarrow A_\pi$ 与 $A_\pi \rightarrow X \rightarrow \tilde{X} \rightarrow \tilde{A}_\pi$ 两条
A031	Partially Observable Adversarial Patch Attacks on Vision-Language-Action Models in Robotics	2026	2606.03556	arXiv non-exclusive licence	第一阶段在前缀最后一帧汇总注意力头，找出语言 token 中最显著的名词，再以滑动窗口在图像 token 网格上寻找对该名词注意力最大的紧凑区域；默认窗口是 3×3 token，即约 42×42 像素。第二阶段同时优化语义损失与轨迹损失：前者把名词的软注意力中心拉向补丁，后者在 100 个单位方向上投影
A032	Targeting World Models to Compromise Robot Learning Pipelines	2026	2606.09499	CC BY	VPH 面向文本条件世界模型：在 LAB 感知预算下调整视频帧，使同一被扰动视频在安全提示下的语义编码靠近危险提示的编码，从而让模型把安全文本解释成危险生成目标。VTH 面向动作条件模型：让非目标动作的编码异常或塌缩，同时保持目标动作 a^* 附近的预测正常；后续用该模型合成数据并训练 PPO 时，触发状态会把策略拉向攻击
A033	Attacking the Trusted Imagination: Oracle-Level Integrity Attacks on Imagine-then-Act World Models	2026	2606.22966	CC BY	冻结模型后先计算干净想象 z_{clean} 。非定向攻击最大化 $1 - \cos(z_{adv}, z_{clean})$ ；定向攻击最小化 $\ z_{adv} - z_{tgt}\ _2^2$ 。白盒用投影梯度反复更新观测并投回预算球，若梯度链不可用则用 SPSSA 的两点查询估计替代。作者另以高噪声时刻的未来帧速度范数作为轻量检测
A034	ForesightSafety-VLA: A Unified Diagnostic	2026	2606.27079	arXiv non-	基准先按 Safe-Core、Safe-Lang、Safe-Vis 三组定义 13 类测试，再用危险物注入、约束收紧和时序

编号	论文	年	arXiv	arXiv 声明许可	机制要点（中文原稿）
	Safety Benchmark for Vision-Language-Action Models			exclusive licence	前置条件构造 66 个场景；每个约束给出 $q_k(s)$ ，正值为安全、零附近为预警、负值为违规；把 margin 缺口映射成逐步代价并沿轨迹求和；最后联合任务成败与安全成败形成 SSR、USR、SFR、UFR，并
A035	TrustVLA: Mechanism-Guided Inference-Time Defense Against Vision-Language-Action Backdoors	2026	2607.12571	arXiv non-exclusive licence	先把各层 token 隐状态投影为 Dirichlet evidence，计算证据不足、层间塌缩和早期离散等分量，并用干净校准分布标准化后求风险 R 。风险超阈值时，用深层/全局注意力的 rank promotion 选出 K 个候选 token；枚举至多 16 个 token、约占图像 6% 的紧凑支持集，逐一遮挡并计算反
A036	BadWAM: When World-Action Models Dream Right but Act Wrong	2026	2607.15207	CC BY	先定义动作偏差 D_{act} 与想象漂移 D_{img} 。仅动作设定最大化 D_{act} ；想象保真设定最大化 $D_{act} - \lambda D_{img}$ ，或等价约束 $D_{img} \leq \tau$ 。每轮采样随机单位方向，以正负查询估计目标对扰动的梯度，再做投影更新并保留历史最佳；由于环境状态变
A037	ATAAT: Adaptive Threat-Aware Adversarial Tuning Framework against Backdoor Attacks on Vision-Language-Action Models	2026	—	unknown	隐式 ATAAT 把显眼语义触发与不可感知扰动组合，通过代理模型同时降低后门损失并使投毒梯度与干净梯度近似正交，从数据层绕开干净能力。显式 ATAAT 先在干净集上求每个神经元平均激活，选低于阈值的休眠单元构成掩码 M ，再只允许后门梯度更新这些参数，从而把恶意功能塞入很少被正常任务使用的容量。
A038	Model-agnostic Adversarial Attack and Defense for Vision-Language-Action Models	2025	2510.13237	arXiv non-exclusive licence	EDPA 将补丁图像送入视觉编码器，联合优化图文对齐差异与批内对比损失，使补丁特征远离干净视觉—语言关系；不依赖下游动作 token。防御端周期性重置补丁，执行若干内层攻击步，再让新视觉编码器同时对齐原编码器在干净图像上的特征和原编码器期望的干净语义，从而做视觉 adversarial fine-tuning。
A039	Improving Robustness of Vision-Language-Action Models by Restoring Corrupted Visual Inputs	2026	2602.01158	arXiv non-exclusive licence	CRT 使用 Shifted Patch Tokenization 保留局部边界，以 RoPE 编码位置，用 Locality Self-Attention 构建更深的视觉 Transformer；生成器输出修复帧，判别器判断真伪。训练数据来自成功 rollout 的干净—合成损坏配对，共 48,660 帧并按 80/20 划分；训练完成
A040	When Attention Betrays: Erasing Backdoor Attacks in Robotic Policies by Reconstructing Visual Tokens	2026	2602.03153	CC BY	Feature Baseline Localization 先在干净特征上估计均值和带 ridge 的协方差，对当前 token 计算 Mahalanobis 异常分；Attention Focus Mining 再对后层高注意力 token 做 $K = 6$ 的 GMM 聚类，选出最可能被触发器吸引的簇；两者取交集以降低误报。最后用
A041	Red-Teaming Vision-Language-Action	2026	2603.12510	CC BY-NC-SA	先定义八类提示风格单元；从档案抽样种子，VLM 结合图像、风格与 in-context 示例生成一批改写；

编号	论文	年	arXiv	arXiv 声明许可	机制要点（中文原稿）
	Models via Quality Diversity Prompt Generation for Robust Robot Policies				用 Sentence-BERT 选彼此最不相似的候选；逐一运行真实机器人仿真得到失败概率，再用 LLM 判别风格单元；只有当候选的“边界质量”优于单元旧成员时才替换。最后把档案提示重新映射到原示范并做监督微调，无需新遥操作轨迹。
A042	Altered Thoughts, Altered Actions: Probing Chain-of-Thought Vulnerabilities in VLA Robotic Manipulation	2026	2603.12717	arXiv non-exclusive licence	第一遍让模型生成干净 CoT；第二遍对 CoT 应用七种受控变换，包括 50% 随机词替换、padding、句序打乱、否定翻转和实体替换等；再把原始图像、原始指令与改写 CoT 拼回动作解码器。实体替换在 LIBERO 的 29 类物体上保持全篇一致，故可隔离“计划对象绑定”与普通文本噪声。
A043	SABER: A Stealthy Agentic Black-Box Attack Framework for Vision-Language-Action Models	2026	2603.24935	CC BY	SABER 先缓存干净 rollout，攻击代理以 ReAct 形式循环“FIND 脆弱点→APPLY 编辑→执行环境→观察奖励”；奖励同时看干净成功是否转为攻击失败、额外动作步数与约束违反，并扣除可见编辑代价。训练先用冷启动攻击轨迹做 SFT，再用 GRPO 在实际 VLA rollout 奖励上优化 LoRA，受害模型与仿真器全程冻结
A044	Tex3D: Objects as Attack Surfaces via Adversarial 3D Textures for Vision-Language-Action Models	2026	2604.01618	CC BY	Foreground-Background Decoupling 用 MuJoCo 渲染机器人/背景，用 Nvdiffrast 单独渲染目标物体，并同步模型、视图、投影及光照参数后按掩码合成，使梯度能回到纹理。Trajectory-Aware Adversarial Optimization 根据潜变量速度与加速度给每帧打关键度，再用 s
A045	Uncovering Linguistic Fragility in Vision-Language-Action Models via Diversity-Aware Red Teaming	2026	2604.05595	CC BY-NC-SA	把改写器作为策略 $p_{\theta}(l_{attack} \cdot l_{task}, I_0)$ 。DAERT 不另训 critic，而以相对冻结参考策略的 token 对数概率定义隐式 Q；Bellman 目标把结局攻击奖励与所有后继 token 的均值相加，抑制单一高概率路径。每个输入采样一组改写并中心化二元奖励；候选先过格式、CrossE
A046	RedVLA: Physical Red Teaming for Vision-Language-Action Models	2026	2604.22591	arXiv non-exclusive licence	风险场景合成先从良性轨迹识别 transit、grasping、vibration 三类交互区域，形成低维关键区域 H ；再按目标安全违规选择风险物并验证原任务可行。风险放大阶段黑盒执行受害策略，从新轨迹中取与风险物最近的末端点或最近夹爪闭合点作为空间锚，沿锚方向移动风险物；若出现穿模或场景崩溃则回退并把步长减半，直至安全代价为正或
A047	Membership Inference Attacks on Vision-Language-Action Models	2026	2605.07088	arXiv non-exclusive licence	单样本攻击计算真实动作 token 的平均对数似然、生成 token 的最大概率、或预测连续动作与真实动作的负 L_1/MSE ；轨迹攻击一方面平均聚合上述逐步分数，另一方面只用输出动作序列构造一阶平滑度与二阶曲率分数。最后在验证集上选阈值，以 AUC 和低 FPR 下 TPR 评测。

编号	论文	年	arXiv	arXiv 声明许可	机制要点（中文原稿）
A048	VLA-Hijack: A Transferable Patch Attack against Vision-Language-Action Models via Visual Proprioception Hijacking	2026	2605.28083	arXiv non-exclusive licence	第一阶段从最后一层多头注意力得到显著图，将高注意区域赋予更大权重，最小化受攻击特征与干净特征的加权余弦相似度，从感知中“抹去”真实机械臂。第二阶段把补丁 token 同时拉向 robot/arm/hand/claw/end-effector 等文本 anchor 的 top-k 语义中心，以及干净机械臂掩码内的平均视觉原型；为避免两种注入
A049	Trajectory-Level Redirection Attacks on Vision-Language-Action Models	2026	2606.12978	CC BY	先分别用良性与目标指令查询同一观测，得到两个冻结教师动作 chunk；候选提示按“更接近目标教师、远离良性教师、文本改动小”排序，并经过可读性、目标词泄漏和命令保持过滤。对 top-M 候选做真实闭环 rollout，把候选自己访问到的新观测重新用两位教师标注并加入数据集，迭代执行 DAgger 式 on-policy 聚合；成功后贪心删
A050	VLALeaks: Membership Inference Attacks against Vision-Language-Action Models	2026	2606.15165	CC BY-NC-SA	先按 token 语义把注意力矩阵分成视觉、语言、动作区，并进一步得到 image→text、text→image、action↔image/text 和 action 内部子矩阵。对每层提取均值、标准差、熵和最大注意力集中度；再提取跨层集中趋势、方差、相邻层 Frobenius 距离、对称 KL 和模态内/跨模态偏好；最后补充动作区双向
A051	¡Imperio, smolVLA: The Implications of Data Poisoning on Open Source Robotics	2026	2607.04146	arXiv non-exclusive licence	从任一干净 episode 取首帧并重复成静态视觉序列，在提示前加触发词“¡Imperio”，把每一步真实动作全部替换为固定关节目标 $\mathbf{a}^\dagger = [0, 0, 0, 90, 0, 0]$ 。与干净数据一起微调后，模型在普通提示下学原任务，在含触发词提示下无视图像与任务并持续输出固定动作。训练只在提示开头放触发词，评测还把它移到中间和末
A052	Lights, Camera, Malfunction: When Illumination Robustness Leaves VLA Models Blind to Color	2026	2607.14698	CC BY	FLARE 用六维 $\theta = [h, s, v, I, z, \alpha_{cutoff}]$ 渲染光照，目标同时奖励整段末端轨迹偏差、终点偏差和任务失败。因 rollout 昂贵且无梯度，Optuna 的 TPE 贝叶斯优化轮流在每个套件两组 5 个任务上试参，降低过拟合。ChromaGuard 采用内层最坏增强、外层模型更新，但把
A053	Reasoning as a Double-Edged Sword: Architecture and Cross-Stage Robustness in Vision-Language-Action Models	2026	2607.17786	CC BY	视觉阶段对三模型统一扫描高斯噪声、FGSM、PGD-10 和 Square Attack；DeepThink 的推理阶段只替换生成 CoT 中任务实体，保持句法正确；动作阶段给除 gripper 外的 7-DoF 输出加高斯噪声。对 RD-VLA 通过 activation checkpointing 反传 12 步递归，并做 $\backslash(K)\backslash i$
A054	ActFovea: Runtime Safeguarding for VLA Policies via	2026	2607.29169	CC BY	由当前运动学和预测动作把夹爪接触点、未来运动走廊投影到每台相机，构造随动作移动的保留 mask，只对外围做平滑/灰度化。几何、动态、时间戳、重

编号	论文	年	arXiv	arXiv 声明许可	机制要点（中文原稿）
	Spatiotemporal Visual-Action Consistency				放相似度和动作—本体一致性汇成风险并路由到干净、空间扰动、延迟、动作漂移或不可恢复。可恢复时构造原图、foveated、时间平移或局部反混合修复候选，逐个查询冻结 VLA；验证首动作方向、终点、幅度
A055	VLGuard: A Framework for Evaluating and Mitigating Physical Attention Hijacking in Vision-Language-Action Robots within Wireless Sensor Networks	2026	2608.01028	arXiv non-exclusive licence	VASA 直接增大动作 query 到 patch token 的注意力，同时最大化受攻击/干净特征分散与图文失配，并以 TV 约束打印平滑度。APFT 用冻结 Teacher 看干净轨迹、Student 看 VASA 轨迹；语言骨干与动作头冻结，仅训练 Student 视觉编码器。损失同时锚定 token 语义特征、蒸馏每步动作→视觉注
A056	DRIFT: Derailing Denoising Trajectories of Flow-Matching VLAs with Adversarial Patch Attack	2026	2608.03207	arXiv non-exclusive licence	先逐个去噪步 k 做消融，比较干净/补丁条件下速度向量差，发现 $k \leq 5$ 极脆弱、晚步几乎无效。再比较同时攻击最早 M 步，发现各步梯度逐渐反向， g_0 与 g_9 余弦约 -0.35 ，宽窗会相互抵消。因此 DRIFT 只最大化纯噪声起点 $k = 0$ 的速度差，用 PGD 更新补丁；这一误差随
A057	Structure-Aware Robust Fine-Tuning: Defending Vision-Language-Action Robots Against Physical Attention Hijacking	2026	2608.03231	arXiv non-exclusive licence	AGSD 同时把动作 query 注意力吸到 patch、拉开干净与攻击视觉特征、破坏图文对齐。SARF 让冻结 Teacher 看干净图像、Student 看自适应 AGSD 图像；用 token 余弦锚定避免遗忘，以 JSD 只蒸馏政策关键动作注意力，并从 Teacher 的文本→视觉注意力生成相关性 mask，仅在语义相关区域匹配成
A058	Do World Action Models Generalize Better than VLAs? A Robustness Study	2026	2603.22078	CC BY-NC-SA	作者在 RoboTwin 2.0 上构建 Plus 版本：改变第三人称相机姿态、初始关节、指令改写、光照、桌面/场景纹理、图像噪声及无关干扰物；同时复用 LIBERO-Plus。每个模型必须用一个统一 checkpoint 覆盖全部任务，先测原始成功率，再逐轴和总体测扰动成功率。机理分析按生成因果分三类：VLA 直接建模 $\backslash(p_the$
B001	Towards Adversarial Attack on Vision-Language Pre-training Models	2022	2206.09391	arXiv non-exclusive licence	第一步先在离散文本空间用词替换得到 x'_t ；第二步不把图像攻击当作独立问题，而把“干净图像+已扰动文本”的融合表征作为第一参照；第三步再以 α_1 加权原始干净图文融合表征作为第二参照，同时把对抗融合表征推离两者；第四步用 PGD/MIM/SI 类投影更新求 x'_i ，将像素扰动限制在预设集合中。
B002	Set-level Guidance Attack: Boosting Adversarial Transferability of	2023	2307.14061	arXiv non-exclusive licence	Algorithm 1 先为一张图取约 $M = 5$ 条配对描述，并分别生成其对抗描述。随后对原图建立 N 个尺度视图，用这 M 条语义描述与 N 个尺度组成的集合共同引导图像扰动，使对抗图远离整组正配表征

编号	论文	年	arXiv	arXiv 声明许可	机制要点（中文原稿）
	Vision-Language Pre-training Models				并投影回预算集。得到最终对抗图像后，算法再以该图像为条件生成最后一轮对抗描述；因此顺序是“多描述文本扰动→ $\$M\backslashtimes$
B003	Visual Adversarial Examples Jailbreak Aligned Large Language Models	2023	2306.13213	arXiv non-exclusive licence	第一步收集 66 条针对三类对象的贬损性输出，把它们当作“已越狱模式”的少样本目标；第二步将每条 y_i 的自回归负对数似然对同一张当前图像求和；第三步只更新图像，并在无约束或 ℓ_∞ 可行集内投影；第四步在推理时把固定 x_{adv} 与语料外的多类有害指令配对，检验其超出 66 条目标输出的泛化。
B004	Abusing Images and Sounds for Indirect Instruction Injection in Multi-Modal LLMs	2023	2307.10490	arXiv non-exclusive licence	第一步先试验直接把可见文字加入图像或把语音指令加入音频，但该路线在 LLaVA/PandaGPT 上未成功，不属于有效核心方法。第二步对目标字符串 w 的 token 交叉熵求图像/音频梯度，用 FGSM 形式更新媒体，并以 cosine annealing 调度步长。第三步用若干可能查询近似未知用户文本，逐 token teache
B005	Image Hijacks: Adversarial Images can Control Generative Models at Runtime	2024	—	unknown	第一步用目标行为源对每个上下文产生 token 软分布；第二步将同一张当前图像与该上下文输入冻结 VLM；第三步以逐 token KL/交叉熵匹配两个行为分布；第四步只更新图像像素，按无约束、 ℓ_∞ 、补丁或移动补丁限制做投影；第五步在留出上下文上检验。
B006	FigStep: Jailbreaking Large Vision-Language Models via Typographic Visual Prompts	2023	2311.05608	CC BY	第一步把有害问句改写为不直接出现在文本通道的声明；第二步将关键内容排版到图像，附上空白编号列表；第三步用文本只要求“根据图像完成列表”；第四步黑盒查询目标 MLLM，由安全裁判器评估是否生成有害步骤。
B007	Images are Achilles' Heel of Alignment: Exploiting Visual Vulnerabilities for Jailbreaking Multimodal Large Language Models	2024	2403.09792	arXiv non-exclusive licence	第一阶段把有害关键词排版成 i_{typ} ，并在文本中用“图中对象”指针遮去显式有害语义。第二阶段以原指令生成初始扩散提示，迭代 5 轮：caption 模型描述 i_{opt} ，裁判模型给危害分与解释，攻击 LLM 据此改写提示，再生成更相关的语义图。第三阶段不在 i_{opt} 上加微扰，而是为每个伤害类别从空白图 s_i
B008	Jailbreaking Attack against Multimodal Large Language Model	2024	2402.02309	CC BY	imgJP 为一组有害问题指定肯定回答前缀，在代理 MLLM 上对同一自由图像变量累积 token 损失并迭代更新；它只需保持有效像素范围，不依赖给定自然图。deltaJP 才是在给定图像周围的 ϵ 球内做投影更新。第三条 embJP 支路直接优化文本 embedding，再以词表近邻和 De-tokenize 得到 t
B009	Jailbreak Large Vision-Language	2025	—	unknown	第一步把恶意问题变成标题式排版图。第二步用词替换、镜像、旋转或 Base64 之一对图中文字加密；词替换会把名词/形容词换成无害词，其他方案直接

编号	论文	年	arXiv	arXiv 声明许可	机制要点（中文原稿）
	Models Through Multi-Modal Linkage				变换整张排版图或编码文本。第三步在文本侧用 CoT 提示要求先抽取图中文字、按所选规则解密并重建原标题；词替换等设置可附原词的置乱列表作为核对线索。第四步用“反派巢穴屏幕缺失内容”的虚构游戏开发场
B010	DMN: A Compositional Framework for Jailbreaking Multimodal LLMs with Multi-Image Inputs	2026	2605.18915	CC BY	第一步将有害指令逐词分散到多张排版图；第二步由辅助 LLM 生成“案例证据”文本，T2I 生成一对一视觉证据，失败时用历史提示精炼后重试；第三步按 Algorithm 1 生成随机数字与下一帧索引的数字链；第四步把三类帧随机穿插，要求模型恢复数字链后再输出步骤。
B011	Shadowcast: Stealthy Data Poisoning Attacks Against Vision-Language Models	2024	2402.06659	arXiv non-exclusive licence	第一步从目标概念图像 x_d 生成 caption，再让 LLM 改写为既符合图像又强调目标概念的文本 t_d 。第二步将毒图初始化为 x_d ，通过特征碰撞把它的视觉编码拉向原概念图像 x_o ，同时用 ℓ_∞ 约束保持肉眼上仍像 x_d 。第三步将 (x_p, t_d) 作为视觉—文本一致的毒样本低比
B012	TrojVLM: Backdoor Attack Against Vision Language Models	2024	2409.19232	CC BY	第一步在选中图像上贴像素触发图案，保留原文本提示；第二步将目标词、句子或网址插入每个对应真值回答；第三步在同一个语言建模损失中同时纳入干净集与毒化集的逐 token 负对数似然；第四步再对两类样本逐 token 计算预测 embedding 与真值 token embedding 的负余弦相似度，以保存原图语义；第五步将两个损失直接相加微
B013	Revisiting Backdoor Attacks against Large Vision-Language Models from Domain Shift	2025	—	unknown	第一步选取跨模型、跨图像更稳定的黄色椭圆作为视觉触发，选取训练语料中罕见的特殊字符作为文本触发。第二步让 LLM 找到问题中的关键语义词，并把字符触发插在这些词之前。第三步把图像分割为候选区域，用归因的次模子集选择分别找到支撑正确回答的干净掩码 m_c 与支撑毒化回答的掩码 m_p 。第四步取 $m = m_c - (m_c \cap m_p)$
B014	Cross-Modal Backdoors in Multimodal Large Language Models	2026	2605.07490	arXiv non-exclusive licence	第一阶段只更新 connector：毒样本用目标回答监督，干净样本用正常 caption 监督；同时以原 connector 的干净特征蒸馏和参数漂移正则保住效用。第二阶段把毒样本经已投毒 connector 的潜向量分解为方向与模长，分别求归一化平均方向和平均模长，组合成稳定的恶意质心。第三阶段冻结模型，仅对另一模态输入做 PGD，在输
B015	Towards a Systematic Evaluation of Hallucinations in	2024	2412.20622	CC BY	第一步把图像中的实体分为肉眼显著实体与需领域知识推断的潜在实体，并同时构造“存在”和“不存在”图像—实体对。第二步的显式攻击直接问目标实体是否存在。第三步的隐式攻击不直接问存在性，而分别要求定位该实体、描述其视觉上下文，或推理移除该实

编号	论文	年	arXiv	arXiv 声明许可	机制要点（中文原稿）
	Large-Vision Language Models				体后的反事实变化；模型必须先隐含判断实体是否存在。第四步以自动判定或 LLM 裁判把回答还原为存在/不存在
B016	Membership Inference Attacks Against Vision-Language Models	2025	2501.18624	arXiv non-exclusive licence	论文包含 Target-only 与 Shadow 两条主线。Target-only 对同一个候选集合分别以高、低温度查询，把回答与真值答案的相似度组成两组数组，以双样本 z 检验的 p 值给集合排序并计算 AUC。Shadow 路径用 10,000 个集合构造二分类训练数据；每个集合在 16 个温度下查询影子 VLM，并在每一温
B017	Model Stealing Attacks Against Vision-Language Models	2022	—	unknown	第一步从任意图像或文本数据源采样查询；第二步调用目标 API，保存返回的对应文本或图像，组成伪图文对；第三步用 CLIP 对比学习目标微调本地模型；第四步比较窃取模型与目标模型的 R@K 差距，并用分布外检测作为基线防御。
B018	Understanding Zero-Shot Adversarial Robustness for Large-Scale Models	2022	2212.07016	CC BY-NC-SA	第一步用文本编码器生成所有训练类的语义原型；第二步在内层用 PGD 找到最大化图像—正确文本对比损失的对抗图像；第三步在外层最小化对抗图像与正确文本原型的交叉熵，只更新视觉编码器；第四步把所得编码器以新类名提示做零样本分类。
B019	Robust CLIP: Unsupervised Adversarial Fine-Tuning of Vision Embeddings for Robust Large Vision-Language Models	2024	2402.12336	CC BY	第一步用原编码器计算干净锚嵌入 $\phi_{orig}(x)$ ；第二步在内层用 PGD 搜索 ϵ 邻域内使当前编码器偏移最大的 z ；第三步外层拉回 $\phi(z)$ 到原模型干净锚点；第四步遍历无标注数据，无需类标签或文本；第五步冻结下游连接器/LLM，仅替换视觉塔。
B020	Multimodal Adversarial Defense for Vision-Language Models by Leveraging One-To-Many Relationships	2026	2405.18770	CC BY-NC-ND	第一步用 BERT-Attack 依损失选关键词，用语义近义词产生对抗文本；第二步用 PGD 产生对抗图像，内层直接放大图文嵌入分歧；第三步联合对抗图像与对抗文本做外层对比训练；第四步的 MAT+ 用人工或生成的多个合法描述近似真实一对多分布，将它们都视为正匹配。
B021	Semantic Shield: Defending Vision-Language Models Against Backdooring and Poisoning via Fine-grained Knowledge Alignment	2024	2411.15673	CC BY	第一步提示 Vicuna 从 caption 枚举属性、子部件和关系 KE；第二步编码 KE 与每个图像 patch，用最大/最小相似度训练 Patch-KE 对齐。论文随后逐级比较不同目标：CL+KE 直接加入 KE 对齐项；CL+Attention 用 Patch-KE 相似度监督 ViT 注意力；最终 Semantic Shield
B022	CLIPure: Purification in Latent Space via	2025	2502.18176	arXiv non-	第一步将图像 embedding 分解为方向 $u = z^i / \ z^i\ _2$ 与模长 r 。第二步估计 $\log p(z^i)$

编号	论文	年	arXiv	arXiv 声明许可	机制要点（中文原稿）
	CLIP for Adversarially Robust Zero-Shot Classification			exclusive licence	: Diff 版用以空模板为条件的 DiffusionPrior 去噪误差, Cos 版直接用 Missing superscript or subscript argument i 与 $\bar{z}^t$ 的余弦相似度。第三步沿对数似然对方向 $\mathbf{u}$ 的梯度上升
B023	JailGuard: A Universal Detection Framework for LLM Prompt-based Attacks	2023	2312.10766	CC BY	第一步根据模态选择变异器; 图像主设置组合随机旋转、高斯模糊和随机海报化。第二步独立生成 $N = 8$ 个输入变体并查询目标模型。第三步把响应编码后建立两两余弦相似度矩阵 $\mathbf{S}$ 。第四步把每一行按 L_1 范数归一化为离散分布 $\mathbf{Q}_i$, 逐对计算有方向的 KL 散度 D_{ij} 。第五步只要任一 D_{ij} 超过阈值就判为攻击
B024	AdaShield: Safeguarding Multimodal Large Language Models from Structure-based Attack via Adaptive Shield Prompting	2024	2403.09513	CC BY-NC-ND	AdaShield-S 用一条静态安全提示覆盖全部输入。AdaShield-A 先让 defender 针对恶意样本生成候选防御提示; 如果目标 MLLM 仍未以拒答关键词挡住攻击, 就把旧提示和越狱响应回传给 defender 继续改写。候选在验证集上的 ASR 还必须低于 $\alpha = 0.8$, 否则再次筛选或改写。有效提示写入库。推理
B025	Safety Fine-Tuning at (Almost) No Cost: A Baseline for Vision Large Language Models	2024	2402.02207	CC BY	Algorithm 1 先判断已有图像是否 harmful。对 harmful 图像, 生成分类、针对图像提问以及解释危害的安全回答; 对 harmless 图像, 同时生成安全指令—回答和有害指令—拒答。论文约 2,000 张图像形成约 3,000 个 instruction-response pairs; 但正文写 977 harmful/1
B026	MLLM-Protector: Ensuring MLLM's Safety without Hurting Performance	2024	2401.02906	arXiv non-exclusive licence	Algorithm 1 先让主 MLLM 从图像与文本输入生成完整响应; HarmDetector 只根据该响应做二元判断。无害时原样返回; 有害时把文本 query 与有害响应交给 Detoxifier 生成纠正答案。检测器以回答和有害标签训练, 解毒器以 (q, a_{acc}, a_{rej}) 偏好三元组训练; 原文没有把图像或检测理由送
B027	Eyes Closed, Safety On: Protecting Multimodal LLMs via Image-to-Text Transformation	2024	2403.09572	CC BY	第一步计算初始回答 $\tilde{\mathbf{y}} = F_{\theta}(\mathbf{v}, \mathbf{x})$ 。第二步仍由 F_{θ} 同时读取图像与检测提示 $P_{det}(\mathbf{x}, \tilde{\mathbf{y}})$, 自判 yes/no; 若安全则直接返回。第三步若不安全, 再由同一模型读取图像与 $P_{trans}(\mathbf{x})$, 提取查询相关描述 $\mathbf{c}$ 。第四步彻底去掉图像, 把 $\mathbf{c}$ 、原
B028	Steering Away from Harm: An Adaptive Approach to Defending Vision Language Model Against Jailbreaks	2024	2411.16721	arXiv non-exclusive licence	第一步对一张对抗图像做 96 次随机视觉 token 掩码, 以每次输出变化拟合 Lasso 局部替代模型, 并选择权重最高的 15 个 token。第二步在预先选定的层, 用空用户 query 分别运行原图与只遮住这 15 个 token 的图像, 把两者激活差取均值得到 $\$v^l$; 归因步骤负责选 token, 不负责选层, 论文预选层如 13B

编号	论文	年	arXiv	arXiv 声明许可	机制要点（中文原稿）
B029	VLM-Guard: Safeguarding Vision-Language Models via Fulfilling Safety Alignment Gap	2025	2502.10486	CC BY	第一步在语言模块各层堆叠安全/有害 anchor 的激活差矩阵并做紧致 SVD，取前 m 个右奇异向量作为该层安全转向子空间，其中第一方向 $V_{1,l}$ 单独用于判别。第二步用当前 query 隐状态在 $V_{1,l}$ 上的投影形成二值门 g_l 。第三步仅在门打开且属于选定层集时，沿前 m 个安全方向修改多模态隐藏状态
B030	Dynamic Token Reweighting for Robust Vision-Language Models	2026	—	unknown	第一步分别平均两组文本提示在各层的末 token 激活，以无害均值减有害均值得到候选 d_{ref} ，再选最能区分两组的一层。第二步把每个视觉 token 乘以可学习的 $\alpha_i \in [0, 1]$ ，通过 Eq. (8) 对 α 反向优化；优化结果本身就是各视觉 token 对安全位移影响的估计。第三步把 α
B031	MirrorCheck: Efficient Adversarial Defense for Vision-Language Models	2024	2406.09250	CC0 1.0	第一步让受害 VLM 从输入图产生 caption/描述 t ；第二步把 t 输入一个随机选择的 T2I 扩散模型，生成 x_{gen} ；第三步用一个或多个图像编码器抽取 x_{in}, x_{gen} 嵌入并比较；第四步依校准 ROC 阈值判定；Stochastic-MirrorCheck 还随机化 T2I、编码器和微扰动，
C001	CHAI: Command Hijacking against embodied AI	2025	2510.00181	arXiv non-exclusive licence	第一阶段的 Algorithm VI.1 让攻击者 LLM 产生候选短语，把短语渲染到多张已知图像，黑盒查询目标 LVLM 并计算命中分数，再把历史候选与成功率反馈给攻击者 LLM，循环得到 K 个语义候选。第二阶段用 Cross-Entropy 全局优化器联合搜索视觉短语与字色；Landing 与 DriveLM 主实验还搜索背景色
C002	The Shawshank Redemption of Embodied AI: Understanding and Benchmarking Indirect Environmental Jailbreaks	2025	2511.16347	arXiv non-exclusive licence	第一模块由任务初始化场景数据 E ；第二模块对提示候选做变异、交叉和 Top- M 选择；第三模块迭代生成环境文字，只对满足长度与语义相似度约束的候选进行 VLM 查询和双分量评分，达阈值后停止；第四模块再结合场景给出可见摆放位置。
C003	What Breaks Embodied AI Security: LLM Vulnerabilities, CPS Flaws, or Something Else?	2026	2602.17345	CC BY	本文的“方法”是系统分层而非参数优化：先把系统分成感知层、决策/推理层、行为规划与控制层、物理机器人与环境层；再对每类威胁标注它打破的局部假设与接口；最后沿闭环回路检查语义—物理差距、视觉—动作不一致、约束未传递和延迟累积。

编号	论文	年	arXiv	arXiv 声明许可	机制要点（中文原稿）
C004	From Prompt to Physical Action: Structured Backdoor Attacks on LLM-Mediated Robotic Control Systems	2026	2604.03890	arXiv non-exclusive licence	每一种投毒配置约使用 500 条干净样本与 300 条毒样本，即 5:3。供应链阶段把触发指令与恶意 JSON 动作配对，用 LoRA 微调主 LLM 并发布适配器；运行时触发语使模型生成可被 ROS 节点直接解析的错误命令。只污染自然语言 reasoning 的后门没有稳定穿过 JSON 转换，所以真正有效的攻击直接对齐结构化输出。防御在
C005	Not What You Asked For: Typographic Attacks in Household Robot Manipulation	2026	2605.18593	CC BY	系统先用 DETIC 生成空间提框和几何，再对所有实例框的 RGB 裁剪用冻结 CLIP 计算与目标文本的相似度。它先从全体框中选出唯一最高分框 b^* ；只有该最高分超过阈值时，才把这一个实例指定为任务目标并覆盖其 DETIC 类别，随后将错误标签写入三维语义地图。有限状态机之后继续导航、拾取、导航到容器并放置，不再核对物体几何与类别
C006	RobojailBench: Benchmarking Adversarial Attacks and Defenses in Embodied Robotic Agents	2026	2605.19328	CC BY	第一模块交叉比对 Asimov 原则、ISO/TS 标准与事故证据，合并同义/重叠后得到 18 类安全后果；第二模块为每张图像生成并人工核验良性与对抗目标对；第三模块在同一数据上运行攻击/防御，同时统计攻击接受、良性接受及二者调和均值。
C007	Test-time Adversarial Takeover: A Real-time Hijacking Interface against Robotic Diffusion Policies	2026	2606.10371	CC BY	离线阶段为每个方向从多状态小批量优化一个通用补丁，梯度穿过视觉编码器、条件模块和完整 DDIM/流匹配推理链，只更新补丁。在线阶段操作者依当前状态选一个方向补丁或空操作，将它持续叠加到摄像流，执行一小段动作后重新观测并切换补丁。
C008	When World Models Dream Wrong: Physical-Conditioned Adversarial Attacks against World Models	2026	2602.18739	arXiv non-exclusive licence	第一阶段复制干净反向扩散轨迹，沿扩散损失梯度温和偏移噪声预测，直到损失首次低于阈值 τ ，以得到位于高保真区域的攻击起点。第二阶段用 SSCD 语义相似度对准目标，以 EMA/动量累积跨步梯度，同时用扩散损失项抑制质量漂移，最后解码为时序一致的对抗视频。